다중 시점 교통 속도 예측을 위한 STGCN 개선 및 재설계

프로젝트 중간 보고서

2026년 10월 24일

초록

도로 센서의 교통 속도는 시간적 변화와 도로망의 공간적 관계에 동시에 영향을 받는다. 본 연구는 시공간 그래프 합성곱 신경망(Spatio-Temporal Graph Convolutional Network, STGCN)을 과거 12개 5분 시점에서 미래 12개 시점의 속도를 한 번에 출력하는 문제에 맞춰 재설계하고, 두 독립적인 교통 데이터셋 METR-LA와 PeMSD4에서 검증하였다. 센서별 입력은 학습 구간의 원관측 속도로 표준화한 값, 하루 중 5분 슬롯의 학습 임베딩, 요일 임베딩, 원관측 여부를 나타내는 마스크로 구성한다. 두 시간–공간–시간 블록에는 희소 Chebyshev 그래프 특징의 공유 투영, 시간층별 입력 잔차, 공간 입력 잔차, 노드·채널 정규화와 직접 다중 시점 출력층을 적용했다.

각 데이터셋을 독립적으로 학습한 세 난수 초기화의 시험 결과에서 최종 모델의 전체 12시점 평균절대오차는 METR-LA 3.052393 ± 0.000805, PeMSD4 1.516887 ± 0.001898이었다. 같은 예측 과제에 맞춰 수정한 STGCN 기준 모델에 비해 각각 4.58%, 6.73% 낮았다. 마지막 예측 시점의 오차 감소율은 각각 7.92%, 9.96%였다. 속도만 쓰는 동일 기본 구조에서 노드·채널 정규화 구성을 적용한 통제 실험도 두 데이터셋에서 개선 방향을 보였다. 다만 최종 모델과 기준 모델의 차이는 여러 설계 선택을 함께 포함하므로 개별 요소의 독립적인 인과 효과로 해석하지 않는다.

연구 과정에서 Receiver MoE도 검토했으나 일관된 예측 우위가 확인되지 않아 최종 모델에 포함하지 않았다. 최종 결과의 의의는 직접 다중 시점 예측에 맞춘 STGCN 구성과, 결측·그래프·분할·체크포인트·평가 절차를 분리하여 재현 가능한 비교를 수행했다는 데 있다.

목차

초록 2

1. 서론 3

2. 이론적 배경과 선행 연구 고찰 4

3. 연구 방법 5

4. 연구 결과 9

5. 결론 및 한계점, 후속 연구 제안 11

6. 폐기된 설정과 실험 12

    6.1 Receiver MoE 구조와 통제 비교 12

    6.2 극단 조건과 라우팅 기전 진단 13

    6.3 비용 민감 라우터 손실 실험 15

참고문헌 17

1. 서론

교통 속도 예측은 과거의 센서 측정과 도로망의 관계를 이용해 미래의 속도를 추정하는 문제다. 한 센서의 속도는 출퇴근 시간대에 반복적으로 변하면서도 주변 도로의 상태 변화와 함께 움직인다. 따라서 시간적 패턴과 공간적 의존성을 동시에 다루는 모델이 필요하다. 본 연구는 시공간 그래프 합성곱 신경망(STGCN)을 한 시간 입력에서 다음 한 시간의 모든 5분 시점을 직접 산출하는 설정으로 재구성하고, 그 선택이 예측 오차에 미치는 영향을 실험적으로 검토한다.

연구 문제의 수학적 범위

데이터셋을 d, 그 데이터셋의 센서 집합을 V_d라 두고 센서 수를 N_d=|V_d|라 하자. 시각 t에 측정된 센서별 속도 벡터는 x_t∈ℝ^{N_d}다. 한 표본의 입력은 X_t=[x_{t−11},⋯,x_t], 목표는 Y_t=[x_{t+1},⋯,x_{t+12}]이다. 모델 f_{θ,d}는 그래프 G_d와 관측 마스크·달력 정보를 함께 받아 Ŷ_t=f_{θ,d}(X_t,G_d,⋯)∈ℝ^{N_d×12}를 출력한다. 모든 시점의 간격은 5분이다. 두 데이터셋은 노드 수와 시간 범위가 달라 각각 별도의 θ, 그래프, 표준화 통계로 학습한다.

입력의 인덱스는 t−11부터 t까지 양끝을 포함하므로 t−(t−11)+1=12개다. 목표도 t+1부터 t+12까지 12개이며, 마지막 목표의 예측 거리는 입력 끝에서 12×5=60분이다. 예측 함수의 입력은 t까지 이용 가능한 값으로 제한한다. 목표의 원관측 마스크는 학습·평가에 포함할 오차 원소를 고르는 데만 사용하고 예측 함수에 미래 정보로 제공하지 않는다.

목표는 단일 시점의 최저 오차가 아니라 미래 12시점 전체의 유효 원관측에 대한 평균절대오차를 줄이는 것이다. 마지막 12번째 시점의 오차는 예측 거리가 가장 먼 시점을 확인하는 보조 지표다. 관측되지 않은 목표값에 대해 정답을 꾸며내거나 보완값을 정답으로 재분류하지 않는다.

연구 목표와 기여

첫째, STGCN의 시간–공간–시간 블록을 직접 12단계 출력에 맞게 정렬했다. 입력 시간 길이와 출력 텐서의 변화를 명시하고, 각 시간층의 자기 입력 잔차와 공간층의 입력 잔차가 어느 지점에 합산되는지를 고정했다. 둘째, 속도뿐 아니라 하루 중 시각, 요일, 원관측 여부를 모델이 구분하도록 입력을 구성했다. 셋째, 동일한 기본 구조의 정규화 통제 실험을 포함해 노드·채널 정규화 구성 전체의 효과를 조사했다. 넷째, 분할과 결측 보완, 그래프 변환, 체크포인트 재개와 시험 평가의 동일성을 확인해 결과 해석의 기반을 만들었다.

이 기여들은 새로운 그래프 합성곱 연산의 보편적 우월성 주장과 다르다. 수정한 기준 모델과 최종 모델 사이에서는 입력, 정규화, dropout 배치, 잔차와 출력 설계가 함께 달라진다. 기준 모델 대비 개선률은 이 설계들의 묶음 효과다. 정규화 통제 실험도 통계 계산 축과 노드별 학습 파라미터를 함께 바꾸므로 두 원인을 독립적으로 식별하지 않는다.

연구 설계의 순서

연구는 ① 각 데이터셋의 인과적인 시간 분할과 그래프 생성, ② 한 시간 입력·한 시간 직접 출력 모델의 구현, ③ 수정 STGCN 기준 모델과의 반복 비교, ④ 입력 및 정규화 구성의 통제 비교, ⑤ 동결된 최종 모델의 반복 평가 순으로 진행됐다. 각 비교는 무엇이 같고 무엇이 다른지를 연구 결과의 표에서 다시 명시한다. 방법의 상세 수식과 데이터 처리는 연구 방법에, 관련 학술적 맥락은 이론적 배경과 선행 연구 고찰에 둔다.

연구 범위는 METR-LA와 PeMSD4 두 고정 센서망의 속도 예측이다. 노드별 정규화 파라미터가 있어 새 센서를 보지 않은 채 일반화하는 문제, 다른 도시로의 전이, 다양한 모델 계열과의 최고 성능 경쟁은 이 실험으로 확인하지 않았다. 결론은 이 범위의 결과와 검증된 비교에 한정한다.

2. 이론적 배경과 선행 연구 고찰

이 장은 왜 시간과 도로망을 함께 모델링하는지 설명하고, 본 연구가 선행 연구와 공유하는 문제 및 다른 평가 경계를 정리한다.

다중 시점 교통 속도 예측

5분 간격 속도 시계열에서 미래 12개 값을 예측하면 5분 앞부터 60분 앞까지 서로 다른 예측 거리가 생긴다. 마지막 시점으로 갈수록 입력 이후의 알려지지 않은 교통 변화가 누적될 수 있다. 한 시점만 출력하는 모델을 12회 호출해 앞선 예측을 다음 입력에 사용하는 재귀 예측은 이전 단계의 오차가 다시 입력에 들어갈 수 있다. 본 연구의 직접 다중 시점 예측은 현재까지의 입력에서 12개 출력 채널을 한 번에 산출한다. 직접 출력이 언제나 재귀 출력보다 우수하다는 일반 주장은 하지 않으며, 이 연구에서는 직접 출력을 고정한 과제를 평가한다.

속도만으로는 비슷한 수치가 서로 다른 교통 문맥을 가질 수 있다. 예를 들어 같은 속도라도 하루 중 시각과 요일에 따라 다음 한 시간의 변화가 다를 수 있다. 결손을 보완한 수치와 실제 센서가 보고한 수치도 동일한 증거가 아니다. 따라서 본 연구는 시간 범주를 학습 임베딩으로 표현하고 실제 원관측 여부를 별도의 이진 채널로 전달한다. 이 표현은 정적 도로 속성이나 미래 사건 정보를 만들어 넣지 않는다.

도로망 그래프와 공간 의존성

센서 집합을 노드 V, 도로망 거리로 정의한 연결을 간선 E로 놓으면 도로망은 그래프 G=(V,E)가 된다. 센서 번호의 근접성에는 물리적 의미가 없으므로 일차원 센서 배열에 합성곱을 바로 적용하는 것은 도로망의 이웃 관계를 표현하지 못한다. 그래프 연산은 특정 센서의 표현을 이웃 센서의 표현과 연결한다. 이 연구는 데이터셋별 가중 무향 그래프를 만들고 원래의 연결 성분을 보존한다.

Yu·Yin·Zhu의 STGCN은 교통 시계열에 시간 합성곱과 그래프 합성곱을 결합한 선행 구조다.[1] Li 등의 DCRNN은 방향 그래프의 확산 연산과 순환형 시간 모델을 결합한 다른 계열이다.[2] 두 논문은 시간·공간 의존성을 함께 다룬다는 문제의식을 보여주지만, 본 연구의 그래프 변환·결측 정책·직접 출력 계약과 동일한 실험은 아니다. 특히 방향 확산을 쓰는 방법과 본 연구의 무향 대칭 정규화 그래프는 공간 관계의 정의가 다르다.

한국ITS학회 논문지의 김성훈·박종혁·최예림 연구는 국내 도로 속도 예측에서 그래프 신경망을 사용하고 그래프 분할로 메모리 병목을 완화하는 접근을 검토했다.[3] 본 연구는 METR-LA와 PeMSD4에서 각 그래프를 분할하지 않고 전체 센서를 한 번에 처리한다. 따라서 두 연구의 시험 수치를 직접 순위로 비교하지 않으며, 그래프 크기와 실행 자원의 선택을 달리한 관련 연구로 고찰한다. 같은 학회지의 박부기·배상훈·정보경 연구는 정상·유고 상황의 도심부 간선도로 속도를 LSTM 및 CNN-LSTM으로 예측했다.[4] 그 연구는 상황에 따른 입력·평가의 중요성을 보여주지만, 본 연구와 데이터·단위·모델이 달라 성능 수치의 직접 비교 대상은 아니다.

시간층과 Chebyshev 공간층

시간 게이트 합성곱은 길이 3의 시간 필터로 두 출력을 만든다. 한 출력은 후보 변화량이고 다른 출력은 sigmoid로 변환한 게이트다. 과거 입력에 맞춘 잔차를 후보 출력에 더한 뒤 게이트를 곱해, 시간 정보를 모두 새 합성곱 결과로 대체하지 않도록 한다. 시간축에 padding을 두지 않는 연산은 출력 길이를 두 칸 줄이므로 잔차도 동일 시점에 맞춰 잘라야 한다.

그래프층은 대칭 정규화 인접 행렬 S로부터 $Z_0=X$, $Z_1=-SX$, $Z_2=2(-S)Z_1-Z_0$를 계산한다. 세 항을 연결한 뒤 공유 선형 투영에 넣는다. 이 연산은 인접 관계를 반복 적용해 0·1·2차 이웃 문맥을 표현한다. 구현은 S^2를 조밀한 행렬로 저장하지 않고 희소 행렬곱을 순서대로 실행한다. 부호가 있는 −S는 이 연구에서 선택한 scaled Laplacian 표현이며, 양의 간선 가중치 자체를 음수 거리로 해석한다는 뜻이 아니다.

이 부호와 재귀는 다음 순서로 얻는다. 자기 연결을 더한 비음수 대칭 가중 행렬을 W=A+I, 그 행 합을 d_i, D=diag(d_i)라 두면 S=D^(−1/2)WD^(−1/2)이고 정규화 라플라시안은 L=I−S다. 임의의 벡터 v에 대해 $v^{\top}Lv=(1/2)\Sigma_{(i,j)}\ W_{ij}(v_i/\sqrt{d_i}-v_j/\sqrt{d_j})^2\geq 0$이다. 또한 $(a-b)^2\leq 2(a^2+b^2)$를 대입하면 $v^{\top}Lv\leq 2\|v\|^2$이므로 L의 고유값은 [0,2]에 있다. 따라서 실제 최대 고유값을 추정하는 대신 유효한 상계 $\lambda_{max}=2$를 고정하면 스케

일된 라플라시안은 L̃=2L/λ_max−I=L−I=−S가 된다. Chebyshev 다항식의 정의 $T_0(M)=I$, $T_1(M)=M$, $T_k(M)=2M\,T_{k-1}(M)-T_{k-2}(M)$에 $M=\tilde{L}$를 대입하고 각각 X에 작용시키면 위 세 항이 나온다. 여기서 2차 항은 이웃 관계를 두 번 적용한 값과 원 입력의 차를 포함하므로 단순한 2-hop 평균은 아니다.

정규화와 해석 가능한 비교의 조건

채널별 정규화는 한 센서·한 시점의 채널 축만을 대상으로 한다. 이 연구의 Node+Channel LayerNorm은 한 배치 원소·한 시간 위치에서 모든 센서와 채널의 평균·분산을 함께 계산한다. 또한 센서·채널 위치마다 학습 가능한 scale·bias를 둔다. 따라서 두 방식을 교체한 실험에서 달라지는 것은 통계 범위와 파라미터 수 두 가지다. 연구 결과는 이를 정규화 구성의 효과로만 표현한다. 고정 센서 집합에 결합된 affine은 새로운 센서에 대한 일반화를 별도 검증해야 하는 이유이기도 하다.

선행 연구가 제시한 아키텍처의 이름만 같다고 동일 기준 모델이 되는 것은 아니다. 본 연구는 원 논문의 코드·데이터 정책을 완전 재현한 실험이 아니라, 현재의 12→12 과제와 동일한 그래프·결측·평가 계약에 맞춘 수정 STGCN 기준 모델을 둔다. 비교 결과를 읽을 때는 이 적응 범위를 유지해야 한다.

3. 연구 방법

이 장은 연구에 참여하지 않은 사람이 데이터 한 표본이 어떻게 만들어지고, 예측값이 어떻게 계산되며, 어떤 원소가 손실과 평가에 들어가는지 확인할 수 있도록 기술한다. 두 데이터셋에는 동일한 절차를 적용하지만 그래프·시간 구간·표준화 통계·모델 가중치는 공유하지 않는다.

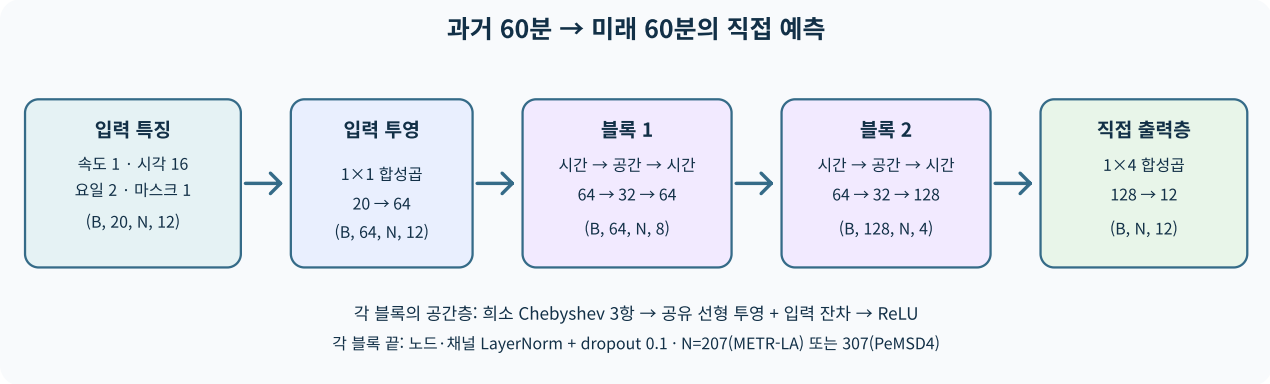


그림 1. 최종 모델의 계산 흐름. 그림의 채널 수는 센서별·시점별 특징 차원이며, N은 데이터셋마다 다른 센서 수다.

표본, 목표와 원관측 마스크

데이터셋 d의 시점 t, 센서 i의 원속도를 $x^{(d)}_{t,i}$, 실제 관측 여부를 $m^{(d)}_{t,i}\in\{0,1\}$이라 둔다. 한 표본은 끝 시점 t까지의 12개 입력과 뒤따르는 12개 목표로 구성한다.

```
입력 시각 : t−11, t−10, ⋯, t
목표 시각 : t+1,  t+2,  ⋯, t+12
입력 형상 : 12 × N_d × 20
예측 형상 : N_d × 12
```

목표 마스크 m^{target}은 입력 마스크와 별도다. 미래 속도를 채워 입력으로 되돌리거나 보완된 미래값을 참값으로 계산하지 않는다. 표본의 분할은 첫 목표 시점 t+1로 결정하며 목표 12개 시점 전체가 한 분할에 있어야 한다. 검증·시험 표본의 입력은 시간상 앞선 분할의 과거 관측을 읽을 수 있지만 목표는 자기 분할에만 속한다.

분할의 시간 인덱스가 양끝을 포함하는 [a,b]이면 허용되는 첫 목표 인덱스 s=t+1은 a≤s와 s+11≤b를 동시에 만족해야 한다. 즉 a≤s≤b−11이다. 입력은 s−12,⋯,s−1이므로 검증이나 시험 분할의 첫 목표를 예측할 때 앞

선 분할의 과거 12칸을 문맥으로 읽을 수 있다. 이 인덱스 조건에서 목표가 경계를 넘지 않으며, 각 데이터셋의 실제 표본 수에는 결손 warm-up 등 별도 제외도 반영된다.

데이터셋	센서 수	학습 기간·표본 수	검증 기간·표본 수	시험 기간·표본 수
METR-LA	207	2012-03-01~05-22 · 23,830	05-23~06-03 · 3,445	06-04~06-27 · 6,901
PeMSD4	307	2018-01-01~02-10 · 11,785	02-11~02-16 · 1,717	02-17~02-28 · 3,445

표 1. 데이터셋별 센서 수와 학습·검증·시험 기간 및 표본 수.

METR-LA의 맨 앞에는 그보다 이전 관측이 없어 인과적으로 보완할 수 없는 결손이 있다. 따라서 최초 51개 학습 후보 window를 warm-up으로 제외한다. 첫 실제 학습 표본은 전체 시계열 index 51에서 입력을 시작하고 index 63에서 목표가 시작된다. 원시 시간축은 보존하며 접근할 수 없는 66개 선행 cell은 결손·인과적 이용 불가로 기록한다. 어느 표본도 그 cell을 참조하지 않는다.

결측 의미와 인과적 보완

입력 속도가 수치로 채워져 있다는 사실과 실제로 센서가 관측했다는 사실을 구분한다. 원관측이면 입력 마스크가 1이고 결손·보완이면 0이다. METR-LA 원자 자료의 정확한 0은 해당 자료의 처리 관례와 전수 검사에 따라 결측 표식으로 분류했다. 물리적으로 실제로 관측된 속도 0을 모든 데이터에서 결측으로 취급한다는 일반 규칙이 아니며 PeMSD4에는 자동 적용하지 않는다.

짧은 결손 구간의 보완 가능 길이는 데이터셋별 학습 자료에서 별도로 계산했다. 센서 × 주중/주말 × 현지 시각으로 고정한 집단에서 내부 원관측 양끝이 있는 길이 1~10의 가상 공백을 만들고 선형 보완의 원단위 절대오차를 계산한다. 충분한 표본이 없는 집단은 같은 센서 내부에서 1시간, 고정 3시간, 하루 통계 순으로 후퇴한다. 학습 끝의 완전한 현지 날짜 14일은 정책 확인에 따로 두고, 그 전 구간에서 날짜 단위 2,000회 재표집으로 자연 변동성 및 인과적 역사 평균·직전값 대체 대비 조건을 만족하는 최대 접두 길이를 구한다. 확인 구간에서 실패하면 더 짧은 접두 길이로 줄인다. 얻은 길이는 데이터셋의 실행 산출값이지 모든 데이터에 미리 적용하는 보편 상수가 아니다.

긴 결손이나 짧은 결손 정책 밖의 값은 시점 이전 원관측만 집계한 역사 평균을 우선 사용한다. 학습 중에는 통계가 시간에 따라 확장되지만 보완값을 관측으로 재투입하지 않는다. 검증·시험에서는 학습 종료 시점에 고정된 시간 슬롯 평균, 시간대 평균을 순서대로 조회하고 둘 다 사용할 수 없으면 직전 원관측값을 이용한다. 해당 분할의 관측으로 평균표를 갱신하거나 새 임계값을 맞추지 않는다. 이 순서는 미래정보 유출을 막는 데이터 계약이다.

속도 표준화와 20차원 입력

데이터셋마다 학습 구간의 유효 원관측 속도 전체에서 한 평균 μ_d와 모집단 표준편차 σ_d를 계산한다. 보완값과 METR-LA의 0 결측 표식은 이 추정에서 제외한다. 표준화 및 역변환은 같은 안정화 항을 사용한다.

$$z(x) = (x - \mu_d) / (\sigma_d + 10^{-8})$$
$$\hat{x}_{original} = \hat{z} \cdot (\sigma_d + 10^{-8}) + \mu_d$$

역변환은 첫 식에 σ_d+10^{-8}을 곱하고 μ_d를 더해 얻는다. 같은 데이터셋의 관측 목표 y와 예측 $\hat{z}$에 대해 $|\hat{x}_{original}-y|=(\sigma_d+10^{-8})|\hat{z}-z(y)|$다. 따라서 표준화 공간의 오차를 그대로 보고하지 않고 역변환 후 원속도 단위의 오차를 집계한다. 10^{-8}은 분모가 0에 가까워지는 상황을 막는 구현 상수이며 검증·시험에서 추정하는 통계량이 아니다.

검증·시험에서 μ_d나 σ_d를 다시 맞추지 않는다. 각 입력 노드·시점의 20차원 벡터는 표준화 속도 1, 하루 288개 5분 슬롯의 학습 임베딩 16, 요일 7개 범주의 학습 임베딩 2, 표준화하지 않는 원관측 마스크 1의 연결이다. 표준화 속도가 결손 보완에서 왔다면 마스크는 여전히 0이다. 센서 ID, 좌표, 도로 등급, 유량·점유율 같은 다른 측정 채널은 최종 입력에 없다. 연결한 벡터에 1×1 합성곱 20→64를 적용한다.

데이터셋별 가중 도로망 그래프

원자료의 방향 관계에서 어느 방향이든 존재하는 센서 쌍을 무향 후보 간선으로 둔다. 두 방향의 거리가 모두 주어지면 그 산술평균을 사용하고, 한 방향만 있으면 관측된 거리를 그대로 사용한다. 무향 비대각 거리 집합의 모집단 표준편차를 σ^G_d라 하여 거리 r_ij를 w_ij=exp[−(r_ij/σ^G_d)²]로 바꾼다. 원래 무향 그래프의 각 연결 성분에서 최소 신장 트리를 구하고, 그 간선 중 데이터셋 전체에서 가장 긴 거리를 r_critical로 정한다. 후보 간선 중 r_ij≤r_critical만 유지한다. 이 과정은 원래 연결 성분을 보존하며 성분 간 새 간선을 만들지 않는다. 원래 연결 성분 수는 METR-LA 1개, PeMSD4 12개다.

거리의 무향화는 양방향 거리 r_(i→j),r_(j→i)가 있으면 (r_(i→j)+r_(j→i))/2로 정의하여 r_ij=r_ji가 되게 한다. 가중치 식은 이 대칭 거리의 표준편차로 거리를 무차원화한 뒤 제곱 지수 함수를 적용하는 선택한 그래프 구성 규칙이다. r=0일 때 1이고 양의 거리에서 단조 감소한다는 성질이 있으나, 관측으로 추정한 확률식이라는 의미는 아니다. 절단 뒤 연결 성분이 보존되는 이유는 각 원래 성분의 최소 신장 트리 간선이 모두 정의상 r_critical 이하이기 때문이다. 따라서 그 트리가 절단 후에도 남아 성분 내부의 모든 노드를 연결한다. 원래 성분 사이에는 후보 간선이 없으므로 새 연결도 생기지 않는다.

생성된 가중 인접 행렬 A는 자기 연결 전의 대각이 0이어야 한다. 자기 연결을 정확히 한 번 추가한 A+I와 차수 행렬 D로 대칭 정규화 행렬 S=D^(−1/2)(A+I)D^(−1/2)를 만든다. scaled Laplacian은 −S로 둔다. 그래프 행렬, 센서 식별자의 정렬 순서와 모델 체크포인트는 같은 데이터셋의 산출물로 묶여야 한다. 입력의 센서 순서가 학습 그래프와 다르면 실행을 중단한다.

여기서 D_ii=Σ_j(A+I)_ij로 놓으면 각 간선의 정규화 계수는 (A+I)_ij/√(D_ii D_jj)다. 자기 연결 때문에 모든 D_ii>0이어서 역제곱근을 정의할 수 있다. L=I−S에 최대 고유값의 유효 상계 2를 적용한 2L/2−I를 전개하면 −S가 된다. 상계의 근거와 Chebyshev 재귀의 유도는 이론적 배경에 자세히 기술했다.

시간-공간-시간 신경망

두 블록의 채널 수는 첫 블록 64→32→64, 둘째 블록 64→32→128이다. 각 블록의 첫 번째·두 번째 시간층은 길이 3의 padding 없는 시간 합성곱이다. 층 입력 U에 대한 게이트 출력은 P,Q=Conv_(1×3)(U)를 두 등분한 후 다음과 같이 정의한다.

$$\mathrm{Temporal}(U) = [P + \mathrm{crop_time}(R(U))] \odot \mathrm{sigmoid}(Q)$$

R은 입력 채널 수가 출력보다 크면 학습 1×1 합성곱, 작으면 0 채널 추가, 같으면 항등 연산이다. crop_time은 원 입력의 처음 두 시간 칸을 잘라 valid 합성곱의 출력과 시각을 맞춘다. 네 시간층마다 자기 입력에 대한 잔차를 따로 사용하며 블록 전체 잔차는 없다. 시간 길이는 12→10→8→6→4다.

시간 입력 길이를 T라고 하면 길이 3, stride 1, padding 0인 합성곱의 출력 길이는 T−3+1=T−2다. 후보 P와 gate logit Q는 모두 (B,C_out,N,T−2)이며, 잔차 R(U)의 앞쪽 두 칸을 제거해야 같은 길이와 대응 시점을 갖는다. 각 블록에 이런 시간층이 두 개씩 있으므로 네 번의 길이 감소를 적용해 12−4×2=4가 된다. 공간층과 정규화는 시간 길이를 바꾸지 않는다.

시간층의 32채널 출력 X에 세 개의 Chebyshev 특징을 적용한다. Z_0=X, Z_1=−SX, Z_2=2(−S)Z_1−Z_0이고, 채널 방향으로 연결하면 96차원이다. 각 블록은 자기 고유의 Linear(96→32,bias=True)를 가지며, 같은 블록 안 모든 센서에 이 투영을 공유한다. 공간 결과는 ReLU(Linear([Z_0;Z_1;Z_2])+X)다. S^2를 조밀하게 계산하지 않고 희소 행렬곱으로 재귀를 수행한다. CUDA 혼합 정밀도에서는 이 재귀만 FP32로 계산한다.

이는 이론적 배경의 T_0,T_1,T_2를 현재 블록 출력 X에 적용한 것이다. 항마다 32채널이므로 연결 길이는 3×32=96이며, 공유 선형층이 이를 다시 32채널로 줄인 다음 차원이 같은 공간 입력 X를 더한다. 둘째 항을 한

번, 셋째 항을 재귀에서 한 번 더 희소 S와 곱하면 되므로 2차 특징 때문에 조밀한 S^2를 만들 필요가 없다.

두 번째 시간층 뒤에는 각 배치 원소·시간 시점의 N×C 값에서 평균·분산을 계산하는 Node+Channel LayerNorm을 적용하고 dropout p=0.1을 잇는다. 정규화에는 노드·채널별 scale과 bias도 포함된다. 따라서 노드마다 다른 학습 파라미터가 생기며 미관측 새 노드에 바로 적용하는 성능을 이 연구는 측정하지 않았다. 마지막 (B,128,N,4) 특징은 Conv2d(128→12,kernel=(1,4),padding=0)를 거쳐 (B,N,12)가 된다. 12개 미래 시점은 재귀 호출 없이 동시에 출력된다.

정규화 직전 값을 H_(b,c,i,τ)라 하면 같은 배치 원소 b와 시간 τ에서 μ_(b,τ)=Σ_(i,c)H_(b,c,i,τ)/(NC), v_(b,τ)=Σ_(i,c)(H_(b,c,i,τ)−μ_(b,τ))²/(NC)를 계산한다. 출력은 γ_(i,c)(H_(b,c,i,τ)−μ_(b,τ))/√(v_(b,τ)+ε_LN)+β_(i,c)다. 여기서 γ,β는 센서와 채널별 학습 파라미터이고 ε_LN은 구현의 수치 안정화 항이다. 블록 끝 채널 수가 64와 128이므로 affine 파라미터 총수는 2N(64+128)=384N이다. 센서 수 207과 307을 대입하면 각각 79,488개와 117,888개이고, 같은 두 층의 채널별 affine만 사용하면 2(64+128)=384개다. 이 차이와 통계 축의 차이가 동시에 존재한다.

출력층의 시간 커널 폭이 남은 길이 4와 같으므로 시간 길이는 4−4+1=1이 된다. 12개 출력 채널을 각각 미래 시점에 대응시키고 마지막 길이 1 축을 제거한 뒤 센서와 시점 축을 배열하면 (B,N,12)다.

학습 손실과 평가 지표

최종 학습 손실은 원속도 단위의 마스크 적용 평균절대오차 하나다. 미니배치 전체의 유효 목표 집합을 Ω라 하면 L=Σ_(b,i,h∈Ω)|ŷ_original−y_original| / |Ω|다. 유효 목표가 없는 배치는 파라미터를 갱신하지 않는다. 역변환과 오차 합산은 혼합 정밀도 학습에서도 FP32로 수행한다.

이 식은 목표 마스크 m_(b,i,h)∈{0,1}를 곱한 E=Σ_(b,i,h)m_(b,i,h)|ŷ−y|와 유효 원소 수 C=Σ_(b,i,h)m_(b,i,h)를 정의하면 L=E/C로 얻어진다. 마스크가 0인 목표의 오차는 분자와 분모 모두에 기여하지 않는다. C=0이면 나눗셈이 정의되지 않으므로 해당 optimizer 갱신을 생략한다.

최초 실험 설정은 Adam 학습률 0.001, weight decay 0, CosineAnnealingLR(T_max=50), 최대 50 epoch, 물리 배치 32, gradient accumulation 1, worker 2와 worker별 prefetch 2다. 검증은 매 완료 epoch마다 수행하고 조기 종료는 초기 20 epoch 뒤부터 patience 10으로 적용한다. 학습 표본은 seed·epoch에 따른 전역 순열에서 빠짐없이 한 번씩 방문하며 마지막 작은 배치도 버리지 않는다.

평가의 전체 MAE는 시험 구간 유효 목표 Ω_test에 대한 절대오차의 합/유효 원소 수다. 예측 시점 h의 MAE는 같은 방식으로 h에 속한 원소만 집계한다. RMSE는 제곱오차 합/유효 원소 수의 제곱근이다. 배치별 평균을 다시 평균하지 않고, 유효 원소 수 0인 부분 지표는 값 없음과 count 0으로 남긴다. 세 seed의 집계는 평균 ± 표본 표준편차(ddof=1)로 제시한다.

전체 집계는 각 배치의 (E_k,C_k)를 더한 (Σ_k E_k)/(Σ_k C_k)다. 배치별 E_k/C_k의 단순 평균은 마지막 작은 배치나 결측 수가 다른 배치에 같은 가중치를 주므로 이 값과 일반적으로 다르다. RMSE는 같은 유효 원소에 대해 √[Σm(ŷ−y)²/Σm]로 계산한다. 세 seed의 지표를 a_1,a_2,a_3라 하면 보고한 중심값은 $\bar{a}=(a_1+a_2+a_3)/3$, 표본 표준편차는 √[Σ_(s=1)^3(a_s−ā)²/(3−1)]다.

비교 대상과 실행 무결성

수정 STGCN 기준 모델은 속도 1차원 입력과 같은 12→12 과제, 같은 데이터셋별 그래프·분할·결측·스케일러 및 직접 출력층을 사용한다. 기준 모델의 두 블록은 [1,32,64], [64,32,128]이고 시간층별 잔차와 공간 입력 잔차 및 Node+Channel 정규화를 가진다. 블록 내부 dropout은 없으며 출력층 직전에 dropout p=0.5를 한 번 적용한다. 이것은 원 논문의 모든 실행 조건을 그대로 재현한 모델이 아니라 현재 과제에 맞게 수정한 비교 모델이다.

분석에서는 같은 기본 구조의 속도 단일 입력·채널 단독 정규화, 속도 단일 입력·노드+채널 정규화, 20차원 입력·노드+채널 정규화를 구분한다. 첫 두 조건의 차이는 정규화 구성의 직접 통제다. 두 번째와 세 번째 조건의 차이는 시간 임베딩·마스크 입력의 묶음과 1→64 대 20→64 투영이며, 별도 run 묶음을 비교한 것이다. 모든

비교의 개별 seed, 선택 체크포인트 및 시험 결과의 연결을 검사하고, 최종 시험 평가는 완료된 run의 검증된 체크포인트에 묶는다.

4. 연구 결과

모든 표의 평균절대오차(MAE)는 각 데이터셋의 원자료 속도 단위에서 실제 관측된 목표 원소를 합산해 계산했다. 평균 ± 표준편차의 표준편차는 난수 초기화 0·1·2의 표본 표준편차(ddof=1)다. 두 데이터셋은 속도 분포와 단위·센서망이 다르므로 METR-LA와 PeMSD4의 MAE 절댓값을 도시 간 성능 순위로 읽지 않는다.

최종 구성과 수정 STGCN 기준 모델

기준 모델과 최종 모델은 각 데이터셋에서 같은 그래프, 시간 분할, 결측 처리, 속도 표준화와 미래 12시점 직접 출력 과제를 사용한다. 최종 모델은 20차원 입력, 블록 구성과 dropout 배치 등 여러 선택이 함께 달라진 전체 설계다.

데이터셋	모델	전체 12시점 MAE	마지막 12번째 시점 MAE
METR-LA	수정 STGCN 기준 모델	3.198754 ± 0.002694	3.752366 ± 0.004147
METR-LA	최종 설계	3.052393 ± 0.000805	3.455025 ± 0.015163
PeMSD4	수정 STGCN 기준 모델	1.626412 ± 0.000481	2.021541 ± 0.000792
PeMSD4	최종 설계	1.516887 ± 0.001898	1.820156 ± 0.004666

표 2. 수정 STGCN 기준 모델과 최종 모델의 전체 및 마지막 시점 평균절대오차.

기준 모델 평균에서 최종 모델 평균을 뺀 절대 오차 감소는 METR-LA 전체 0.146361, 마지막 시점 0.297341, PeMSD4 전체 0.109525, 마지막 시점 0.201385다. 기준 모델 평균을 분모로 한 상대 감소율은 다음 그림과 같다.

상대 감소율은 각 데이터셋·지표에서 100×(MAE_기준−MAE_최종)/MAE_기준으로 계산한다. 예를 들어 METR-LA 전체 구간은 100×(3.198754−3.052393)/3.198754=4.58%(소수 둘째 자리 반올림)다. 같은 연산을 METR-LA 마지막 시점, PeMSD4 전체·마지막 시점에 각각 적용하면 7.92%, 6.73%, 9.96%가 된다. 이 비율은 각 데이터셋 자신의 기준 오차를 분모로 사용한다.

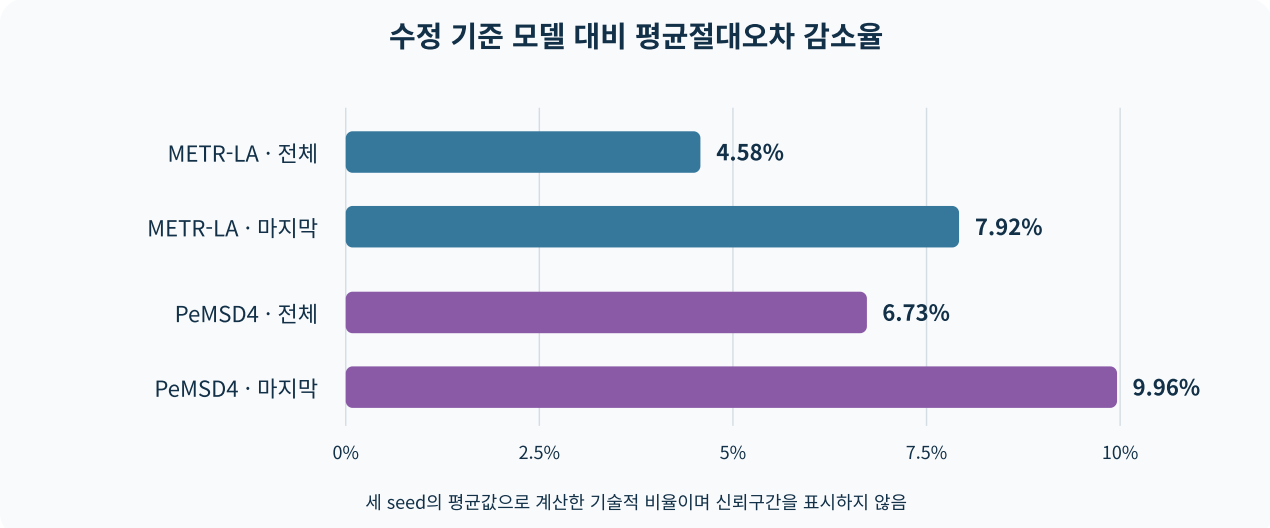


그림 2. 수정 STGCN 기준 모델에 대한 최종 구성의 상대 평균절대오차 감소율. 서로 다른 데이터셋의 절대 MAE를 같은 축에 놓지 않고, 각 데이터셋 기준 모델 평균으로 나눈 비율만 나타냈다.

이 비교의 최종 구성 값은 별도로 완료한 반복 실험의 세 seed 집계이고, 기준 모델 값은 초기 수정 기준 모델 실험의 세 seed 집계다. 위 비율은 평균값 사이의 기술적 차이다. 이 비교에 대한 날짜별 짝지은 불확실성 구간이나 형식적 우월성 검정을 계산한 값이 아니므로 그림의 막대를 통계적 신뢰구간으로 해석하지 않는다.

정규화 구성의 통제 비교

속도 한 채널을 사용하는 동일 기본 구조에서 두 블록 끝의 정규화만 교체한 실험이 있다. 채널 단독 정규화는 한 노드·시점의 채널만 정규화한다. 노드+채널 정규화는 한 배치 원소·시점의 모든 노드와 채널을 정규화하고 노드별 affine 파라미터를 학습한다.

데이터셋	정규화 구성	전체 12시점 MAE	마지막 시점 MAE
METR-LA	채널 단독	3.536261 ± 0.003330	4.418375 ± 0.004264
METR-LA	노드+채널	3.178323 ± 0.000604	3.718622 ± 0.001933
PeMSD4	채널 단독	1.781408 ± 0.000219	2.353939 ± 0.000597
PeMSD4	노드+채널	1.607812 ± 0.002386	1.999779 ± 0.005172

표 3. 속도 단일 입력 구조에서 정규화 구성에 따른 평균절대오차.

전체 구간에서 노드+채널 구성의 평균 MAE는 METR-LA 0.357938(약 10.12%), PeMSD4 0.173596(약 9.75%) 낮다. 마지막 시점에서는 각각 0.699753(약 15.84%), 0.354160(약 15.05%) 낮다. 세 seed의 짝별 차이도 두 데이터셋과 두 지표에서 같은 방향이었다. 반면 이 실험에서는 정규화 통계 축과 노드별 scale·bias의 수가 함께 바뀌었다. 두 블록의 affine 파라미터는 채널 단독 구성에서 384개, 노드+채널 구성에서 METR-LA 79,488개, PeMSD4 117,888개다. 따라서 정규화 구성 전체의 효과만 결론낼 수 있다.

위 절대 감소는 같은 행 쌍의 채널 단독 평균에서 노드+채널 평균을 뺀 값이고, 괄호 안 비율은 해당 채널 단독 평균으로 다시 나눈 값이다. 예를 들어 METR-LA 전체는 $3.536261-3.178323=0.357938$, $100\times0.357938/3.536261\approx10.12\%$다. affine 수는 연구 방법의 384N에 센서 수 207 또는 307을 넣어 계산한 것이다. 이 산술은 관측된 구성 차이를 정량화하며 어느 한 변경의 독립 효과를 추정하지 않는다.

입력 표현을 더한 비교

노드+채널 정규화와 공유 공간 투영을 유지한 속도 단일 입력 구성의 전체 MAE는 METR-LA 3.178323, PeMSD4 1.607812였다. 시간 슬롯·요일 임베딩과 원관측 마스크를 포함한 최종 20차원 입력 구성의 전체 MAE는 각각 3.052393, 1.516887이다. 마지막 시점도 각각 3.718622→3.455025, 1.999779→1.820156으로 낮아졌다. 이 비교는 시간 문맥과 관측 여부를 함께 표현한 입력 구성이 같은 정규화 계열에서 유용하다는 해석을 지지한다.

단, 두 수치는 독립적으로 완료된 실험 집계다. 입력의 네 성분 중 시간 슬롯, 요일, 마스크 각각을 하나씩 제거한 결과가 아니며, 입력 투영의 크기도 달라진다. 따라서 “마스크만으로 얼마 개선됐다” 또는 “요일 정보가 정확히 얼마 기여했다”는 수치는 이 연구에서 산출하지 않았다.

예측 거리와 반복의 해석

마지막 시점의 개선율이 전체 구간의 개선율보다 두 데이터셋에서 크다. 이는 12번째 시점의 평균 오차가 기준 모델에 비해 더 많이 감소했다는 기술적 결과이지, 모든 개별 미래 시점에서 오차가 단조롭게 감소했다는 뜻은 아니다. 세 seed 결과의 표준편차는 모델 초기화에 따른 변동의 한 측면을 보여주지만, 모집단 도시·날짜를 재표집한 불확실성이나 다른 센서망으로의 외삽 불확실성까지 포함하지 않는다.

최종 모델과 비교 모델의 실험은 그래프·스케일러·결측·표본 정의를 데이터셋별로 고정하고, 유효 목표의 오차 합과 count를 누적했다. 시험 결과는 선택된 검증 체크포인트와 연결해 기록했다. 이 절차는 같은 숫자를 다시 설명할 수 있는 실험 무결성의 근거다. 새 데이터셋에서 성능이 같을 것이라는 보증은 아니다.
이 결과의 주장 수준은 결론 및 한계점, 후속 연구 제안에서 정리한다. 모델의 수식과 분할은 연구 방법에 있다.

5. 결론 및 한계점, 후속 연구 제안

결론

본 연구는 과거 한 시간의 센서 속도에서 다음 한 시간의 12개 5분 속도를 직접 예측하도록 STGCN을 재구성했다. 학습 구간 속도 표준화, 하루 중 시각·요일 임베딩, 원관측 마스크, 두 시간-공간-시간 블록의 잔차 정렬, 희소 Chebyshev 공간 연산, 노드·채널 정규화와 직접 출력층을 하나의 명시적인 모델 계약으로 연결했다. METR-LA와 PeMSD4에서 최종 모델의 세 seed 전체 구간 평균절대오차는 수정 STGCN 기준 모델보다 각각 4.58%, 6.73% 낮았고, 마지막 시점 오차는 각각 7.92%, 9.96% 낮았다.
동일 기본 구조의 속도 단일 입력 통제 실험에서는 채널 단독 정규화를 노드·채널 정규화 구성으로 교체했을 때 두 데이터셋 모두 오차가 감소했다. 시간 문맥·관측 마스크를 결합한 입력 구성도 그 다음 비교에서 더 낮은 오차와 연결됐다. 따라서 연구의 핵심 성과는 다중 시점 교통 속도 예측에 맞춘 STGCN 구성의 성능 개선을 두 센서망에서 확인하고, 그 결과를 결측·그래프·분할·평가 계약과 함께 설명할 수 있게 한 것이다.

주장 범위와 한계점

첫째, 수정 기준 모델 대비 개선은 여러 설계 선택의 묶음 효과다. 입력 특징, 시간층별 잔차, 노드·채널 정규화, dropout 배치와 직접 출력층의 개별 인과 기여를 모두 분리하지 않았다. 특히 노드·채널 LayerNorm의 통계 계산 축과 센서별 affine 파라미터 수가 함께 바뀌었기 때문에, 개선을 통계 축 하나 또는 추가 파라미터 하나로 귀속할 수 없다.
둘째, 연구 대상은 METR-LA와 PeMSD4의 고정 센서 집합이다. 센서 순서와 노드별 affine 가중치를 맞춰야 하므로 훈련 중 보지 못한 센서나 다른 도시의 네트워크에 즉시 적용되는지 검증하지 않았다. 두 데이터셋과 세 난수 초기화로부터 모든 교통망에 대한 일반적 우월성을 추정할 수 없다.
셋째, 비교의 중심은 이 연구의 데이터·출력 과제에 맞춰 수정한 STGCN이다. 원 논문의 완전한 재현이나 최신 Transformer·attention 모델 전체와의 최고 성능 경쟁이 아니다. 서로 다른 자료·단위·분할의 논문 숫자를 직접 비교하지 않았다. 결손 처리의 인과성은 검사했지만 결측률이나 연속 결손 길이를 인위적으로 바꾼 별도 강건성 비교는 하지 않았다.
마지막으로 Receiver MoE를 포함한 역사적 확장은 같은 기본 구조의 단일 투영보다 일반·극단 조건의 예측에서 일관된 이득을 확인하지 못했다. 이 결과는 폐기된 설정에 남겨 두었으며, 모든 전문가 모형이 무효하다는 주장으로 일반화하지 않는다. 최종 모델은 단일 공유 공간 투영을 쓰도록 동결했고 현재의 모델 구조 탐색은 종료됐다.

후속 연구 제안

후속 검증을 별도로 설계한다면 먼저 주장 단위를 더 잘 분해하는 실험이 필요하다. 동일 입력·학습 조건에서 노드·채널 정규화의 통계 축과 affine 파라미터의 효과를 따로 통제하고, 시간 슬롯·요일·원관측 마스크를 각각 제거한 비교를 사전에 정의할 수 있다. 이는 현재의 묶음 개선을 더 세밀한 기여로 설명하기 위한 제안이며, 이미 얻은 결과의 해석을 소급 변경하지 않는다.
두 번째로 고정 노드 바깥의 일반화가 필요하다. 센서 일부를 학습에서 제외하거나 다른 도시·시기의 그래프에 적용할 때 어떤 노드별 파라미터가 재사용 가능한지 검증할 수 있다. 날짜와 센서의 종속성을 고려한 더 많은 seed·기간·데이터셋 반복, 예측 시점별 불확실성, 결손 강건성도 별도의 사전 정책과 함께 평가해야 한다. 최신 예측 모델과 비교하려면 입력·그래프·결측·분할·원단위 지표를 먼저 통일해야 한다.

6. 폐기된 설정과 실험

이 영역은 최종 모델에서 제외한 Receiver MoE 구조와 그 검증 과정을 기록한다. “폐기”는 이 연구의 최종 모델 설정으로 채택하지 않았다는 뜻이다. 부정 결과를 삭제하거나 전문가 모델 일반의 무효성을 선언한다는 뜻이 아니다. 현재 동결된 모델은 연구 방법에 기술한 블록별 단일 공유 공간 투영을 사용한다.
초기 가설은 센서의 현재 상태에 따라 여러 공간 투영 가운데 하나를 고르면 같은 투영을 전체 센서에 적용하는 것보다 예측이 좋아질 수 있다는 것이었다. 먼저 초기 제안 모델과 수정 STGCN 기준 모델을 비교했고, 입력과 정규화의 혼입을 확인한 뒤 같은 기본 구조에서 공간 단계만 다른 모델을 재비교했다. 일반 구간의 이득이 확인되지 않자 사전에 정의한 어려운 교통 조건, 라우팅의 실제 작동 여부, 목표값을 본 비배포 상한, 선택 비용을 이용한 보조 손실까지 순서대로 검사했다.

실험 단계	확인된 사실	최종 해석
초기 제안 모델	두 데이터셋의 전체·마지막 시점 MAE가 수정 기준 모델보다 높음	입력·정규화 등 여러 차이가 있어 전문가 선택만의 효과로 귀속할 수 없음
동일 기본 구조 비교	단일 공간 투영보다 네 전문가의 평균 MAE가 두 데이터셋에서 조금 높음	추가 구조를 정당화할 일관된 이득이 없음
극단 조건의 사전 정의 비교	주 조건 우월성이 각 데이터셋 세 seed 중 한 번만 통과	어려운 상태의 우월성도 일관되지 않음
검증 구간 기전 감사	모든 전문가가 사용되고 전문가 교체는 오차를 높임	라우팅은 작동했으나 단일 투영 대비 우위를 뜻하지 않음
비용 민감 손실	평균 전체 MAE가 두 데이터셋에서 조금 높음	최종 손실로 채택하지 않음

표 4. 최종 모델에서 제외한 설정의 단계별 실험 결과.

세부 내용은 구조와 통제 비교, 극단 조건과 기전 진단, 비용 민감 라우터 손실에 있다. 세 문서는 연구 과정의 기록이며 새 모델 구조 실험의 승인 목록이 아니다. 연구 전체의 결론은 결론 및 한계점, 후속 연구 제안에 둔다.

6.1 Receiver MoE 구조와 통제 비교

Receiver Mixture of Experts(MoE)는 도로망에서 정보를 받는 센서 노드마다 공간 투영 전문가를 선택하도록 설계한 과거 구조다. 최종 모델의 두 블록은 각각 하나의 공유 선형 공간 투영을 사용한다. 이 역사적 구조에서는 각 블록의 공간층에 네 개의 전문가 선형층을 두고, 노드별 라우터가 선택한 출력을 사용했다.

라우팅과 전문가 계산

첫 블록 첫 시간층의 32채널 출력에서 노드별 시간 attention 가중치를 얻어 시계열을 요약하고, 선형 변환으로 16차원 표현을 만든다. 여기에 데이터셋별 센서 ID의 학습 임베딩 2차원을 연결해 18차원 라우터 입력을 만든다. ID 임베딩은 학습할 때 원소별 dropout p=0.5를 거친다. 라우터는 네 전문가의 softmax 확률을 계산하고 기본 설정에서는 가장 높은 전문가 한 개를 고른다. 이 선택과 확률은 두 블록과 모든 남은 시간 위치에서 공유한다. 블록별로 다시 선택하지 않는다.
전문가 e는 세 Chebyshev 항의 96차원 연결을 Linear_e(96→32,bias=True)로 투영한다. 선택 전문가의 출력에 원래 softmax 확률을 곱하고 공간 입력 32채널을 더한 뒤 ReLU를 적용한다. 선택 gate를 무조건 1로 키

우지 않았다. 네 전문가의 가중치는 블록마다 별개다. 보조 손실로 선택 빈도와 전체 확률의 관계를 이용한 부하 균형 항, 전문가 가중치의 쌍별 절대 cosine 유사도 항을 사용했다. 이 항들은 특정 전문가만 지속 선택되는 것을 억제하려는 장치이며 예측 이득 자체를 보증하지 않는다.

라우터의 네 logit을 a_e라 하면 확률은 p_e=exp(a_e)/Σ_(k=1)^4 exp(a_k)이고 선택 번호는 e*=argmax_e p_e다. Σ_e p_e=1로 정규화되지만 실제 공간 연산에서는 모든 전문가의 가중 평균을 취하지 않는다. 세 Chebyshev 항의 연결을 Z라 할 때 결과는 ReLU[p_(e*) Linear_(e*)(Z)+X]다. 단일 투영의 ReLU[Linear(Z)+X]와 비교하면 선택된 투영 가중치뿐 아니라 p_(e*)가 분기 크기도 바꾼다. 따라서 이 비교만으로 전문가 수와 gate 크기의 영향을 따로 분해할 수 없다.

초기 비교에서의 혼입

초기 네 전문가 모델의 세 seed 평균 전체 MAE는 METR-LA 3.398263 ± 0.060806, PeMSD4 1.683229 ± 0.017137이었다. 수정 STGCN 기준 모델의 평균은 각각 3.198754 ± 0.002694, 1.626412 ± 0.000481이었다. 마지막 시점도 METR-LA 4.091994 대 3.752366, PeMSD4 2.155136 대 2.021541로 높았다. 그러나 이때는 전문가 유무와 동시에 입력 차원, 정규화, dropout 위치와 공간 연산이 달랐다. 초기 차이를 전문가 구조의 순수한 효과로 주장할 수 없는 이유다.

이후 속도 단일 입력의 같은 기본 구조에서 Channel-only 정규화를 Node+Channel 구성으로 바꾸자 큰 성능 격차가 회복됐다. 정규화 통계 축과 노드별 affine 파라미터 수를 함께 바꾼 결과이므로 연구 결과에서는 결합된 정규화 구성의 효과로 설명한다.

동일 기본 구조의 비교

20차원 입력, 노드·채널 정규화, 두 블록의 채널 수, dropout, 직접 출력층과 데이터 계약을 맞추고 공간 단계만 단일 공유 투영 또는 네 전문가 라우팅으로 비교했다. 먼저 완료한 반복에서는 METR-LA 전체 MAE가 단일 투영 3.058362 ± 0.009580, 네 전문가 3.065634 ± 0.001426이었다. PeMSD4는 각각 1.517752 ± 0.001979, 1.518444 ± 0.004022였다. 마지막 시점 평균도 단일 투영이 낮았으며, seed별 차이의 부호는 섞였다. 별도의 새 반복 비교에서도 단일 투영의 전체·마지막 시점 평균이 두 데이터셋 모두 더 낮았다.

네 전문가는 best·final checkpoint에서 모두 선택됐다. 따라서 “아무 전문가도 쓰이지 않았다”는 붕괴로 오차 차이를 설명할 수 없다. 반대로 선택 빈도가 균형을 이룬다고 서로 다른 전문가가 안정적인 기능을 학습했거나 정확도가 높아졌다는 뜻도 아니다. 이를 분리하기 위해 극단 조건과 기전 진단을 수행했다. 전문가 수, top-1 gate의 크기, 라우터 입력, 부하 균형과 직교성 항의 독립 효과를 모두 완전히 분리한 실험은 아니다.

6.2 극단 조건과 라우팅 기전 진단

평균 예측 오차가 개선되지 않아도 어려운 교통 상태에서는 전문가 선택이 도움이 될 수 있다는 역사적 가설을 별도 시험했다. 이를 위해 20차원 입력·노드+채널 정규화·기본 블록을 공통으로 둔 단일 공유 공간 투영 모델과 네 전문가 모델의 새로운 반복 학습 결과를 비교했다. 조건과 주 판정을 시험 집합을 본 뒤 바꾸지 않도록 학습 자료에서 임계값을 계산하고 검증 구간에서 표본 수·날짜·센서 분포를 감사한 후 정책을 동결했다.

사전 정의한 교통 조건

입력 상태에서 센서의 상대 속도, 급격한 속도 감소, 가중 1-hop 이웃 속도와의 공간 불일치를 계산했다. 주 조건인 Tail10 triple은 상대 속도가 학습 자료의 하위 10% 이하, 속도 변화가 절댓값 분포 상위 10%에 해당하는 감속, 공간 불일치가 상위 10% 이상인 상태의 교집합이다. 경계값이 같은 표본의 포함 규칙까지 평가 정책에 고정했다. 주 지표는 조건에 해당하는 유효 목표의 미래 12시점 전체 원단위 MAE이며 마지막 시점 MAE는 부지표다. 완화·강화한 교집합이나 단일 저속·감속·회복·공간 불일치 조건은 설명용 진단이어서 별도 우월성 판정을 하지 않았다.

이 세 양은 예측 시작 직전의 원관측에서 만든다. 센서 i의 학습 원관측 속도 95% 분위수를 높은 속도 기준 u_i라 두되 이를 실제 자유류 속도라고 단정하지 않는다. 현재 속도를 v_(i,t)라 하면 v_rel=v_(i,t)/u_i, δ_rel=[v_(i,t)−v_(i,t−1)]/u_i다. 변화율은 연속된 두 5분 시점이 모두 원관측일 때만 계산한다. 공간 양은 원관측인

1-hop 이웃 j의 상대 속도를 가중 평균한 값과 현재 센서의 상대 속도 차이의 절댓값, 즉 g_sp=|v_rel−Σ_j w_ij m_(j,t)(v_(j,t)/u_j)/Σ_j w_ij m_(j,t)|다. 분모가 양수인 원관측 이웃이 하나 이상 있고 현재 센서도 원관측일 때만 정의한다. 이렇게 나누면 이웃 수와 가중치 총량이 달라도 이웃의 평균 상대 속도와 비교한다.

세 입력 진단량을 각각 v_rel, δ_rel, g_sp라 쓰고 학습 자료에서 얻은 분위수를 $q_{10}(v_rel)$, $q_{90}(|\delta_rel|)$, $q_{90}(g_sp)$라 쓰면 조건 지시자는 $I_Tail10=1\{v_rel\le q_{10}(v_rel)\}\cdot 1\{\delta_rel\le -q_{90}(|\delta_rel|)\}\cdot 1\{g_sp\ge q_{90}(g_sp)\}$다. 세 지시자를 곱하면 하나라도 거짓일 때 0이고 세 조건이 모두 참일 때만 1이므로 교집합이 된다. 절댓값 변화의 상위 임계값 앞에 음수를 붙이는 것은 큰 변화 중 감속만 선택하기 위해서다. 이 분위수는 시험 오차에서 역산하지 않고 학습 원관측으로 고정한다.

주 조건은 유효 목표 수 10,000개 이상, 모든 시험 현지 날짜에 조건이 존재, 고정 센서의 50% 이상에 조건이 존재해야 평가한다. 날짜 블록은 최소 두 개가 필요하다. 표본 지원이 부족하면 그 데이터셋·seed의 주 판정을 insufficient_support로 중단한다. 진단 그룹에 유효 표본이 0개일 때 다른 그룹의 오차로 채우지 않고 오차값 없음·count 0을 유지한다. 완료한 여섯 데이터셋·seed 비교는 모두 주 조건 지원 기준을 통과했다.

날짜 단위의 짝지은 재표집

같은 데이터셋·seed의 두 모델을 같은 현지 달력 날짜로 묶고 10,000회 날짜 블록을 복원추출했다. 각 표본의 MAE는 날짜별 MAE를 단순 평균하지 않고 선택 날짜의 절대오차 합을 합산한 뒤 유효 목표 수의 합으로 나눠 다시 계산했다. 두 모델의 차이는 Δ=MAE_네전문가−MAE_단일투영이다. 주 조건 우월성은 Δ의 단측 95% 분위수가 0 미만인 경우다. 전체 구간 안전 조건은 상대 MAE 차이의 단측 95% 분위수가 1% 이하인 경우다. seed별 결과를 보고했으며 여러 seed를 하나의 표본으로 합쳐 추론하지 않았다.

날짜 k의 절대오차 합과 유효 목표 수를 모델별 (E_(M,k),C_(M,k))라 하면, 복원추출한 날짜 인덱스열 $k_1,\cdots,k_K$의 집계는 MAE_M^*=Σ_j E_(M,k_j)/Σ_j C_(M,k_j)다. 한 날짜의 유효 수가 다른 날짜보다 많을 수 있으므로 $K^{-1}\Sigma_j[E_{(M,k_j)}/C_{(M,k_j)}]$는 같은 원소별 MAE가 아니다. 두 모델에 같은 인덱스열을 적용한 뒤 Δ*=MAE_네전문가^*−MAE_단일투영^*을 계산한다. 반복에서 얻은 Δ*의 0.95 분위수가 0보다 작다는 규칙은 선택 날짜 변동 아래 오차 감소 방향이 유지되는지 검사한다. 전체 구간 안전 규칙은 같은 표본에서 (MAE_네전문가^*−MAE_단일투영^*)/MAE_단일투영^*의 0.95 분위수를 0.01과 비교한다.

예측 결과와 선택 분포

새 반복의 전체 구간 세 seed 평균은 METR-LA에서 단일 투영 3.052393 ± 0.000805, 네 전문가 3.062838 ± 0.003345, PeMSD4에서 각각 1.516887 ± 0.001898, 1.518178 ± 0.003681이었다. 모든 seed가 전체 구간 상대 오차의 1% 안전 조건을 통과했지만 이는 통계적 동등성의 증명이 아니다. 주 극단 조건 우월성은 두 데이터셋 모두 세 seed 중 한 번만 통과했고 세 seed의 오차 차이 방향도 일치하지 않았다.

데이터셋	단일 투영의 주 조건 MAE	네 전문가의 주 조건 MAE	우월성 통과 seed
METR-LA	16.500784 ± 0.338147	16.428571 ± 0.098767	1/3
PeMSD4	10.898481 ± 0.047915	10.908481 ± 0.056736	1/3

표 5. 사전 정의 극단 조건에서 두 모델의 평균절대오차와 우월성 통과 수.

METR-LA의 주 조건 평균만 보면 네 전문가가 낮지만 seed 0과 1에서는 오히려 높았다. PeMSD4에서는 세 seed 중 두 개가 방향상 낮았더라도 엄격한 우월성 조건을 통과한 것은 하나다. 주 조건의 라우팅 엔트로피는 전체 상태보다 낮고 가장 높은 gate 확률과 1·2위 차이는 컸다. 이는 선택 분포가 조건에 반응한다는 사실이지 예측 우위의 증거가 아니다.

검증 구간의 작동 원인 감사

전문가 모델 여섯 best checkpoint를 검증 구간에서만 다시 살폈다. 모든 run에서 미선택 전문가가 0개였고, 실제 라우팅 예측의 MAE는 같은 전문가 한 개를 모든 노드에 고정한 각 반사실 예측보다 낮았다. 선택한 전문가 번호를 순환해서 잘못 적용하면 모든 run에서 MAE가 높아졌다. gate를 통과한 전문가 분기의 RMS는 공간 입력 잔차 RMS의 약 0.61~1.02배였다. 그러므로 전문가 경로가 단순히 사라지거나 라우터가 완전히 고정된 것은 아니었다.

목표값을 관측한 뒤 각 노드·window에 가장 낮은 오차의 전문가를 이어 붙인 Oracle은 실제 라우팅보다 검증 MAE가 METR-LA 10.61% ± 1.29%, PeMSD4 13.67% ± 0.87% 낮았다. 실제 라우터의 전문가 번호가 Oracle 번호와 일치한 비율은 각각 29.13%, 35.84%였다. 이 Oracle은 서로 다른 전문가 고정 그래프 세계의 출력들을 목표값으로 선택해 결합한 비배포 상한이다. 실제 예측 성능이나 단일 투영 대비 가능 이득으로 읽을 수 없다.

학습 구간의 Oracle 번호로 작은 분류기를 맞춘 뒤 검증 구간에 적용한 진단에서는 일반 분류 정확도가 여섯 checkpoint 모두 현재 라우터보다 높았다. 그러나 네 전문가의 균형 정확도 차이는 METR-LA 평균 +0.38%p, PeMSD4 평균 −1.05%p에 그쳤다. 전문가 1·2위 오차 차이가 큰 사례에는 일부 동적 입력 신호가 있었지만 PeMSD4와 METR-LA의 선택 비용 개선 방향은 같지 않았다. 따라서 전문가 간 다른 출력이 있다는 사실과, 배포 시점에 유용한 전문가를 안정적으로 고를 수 있다는 사실을 구분해야 한다.

마지막 한정 실험은 비용 민감 라우터 손실에 기록했다. 폐기된 설정으로 돌아가면 종료 결정을 볼 수 있다.

6.3 비용 민감 라우터 손실 실험

앞선 진단은 전문가 간 예측 차이가 존재해도 현재 라우터가 목표값을 보지 않고 가장 유리한 전문가를 안정적으로 고른다는 근거를 제공하지 못했다. 이에 기존 네 전문가 구조의 예측 손실과는 분리된 한 개의 라우터 학습 보조 목적 L_cost를 실험했다. 이 절의 모델·손실은 동결된 최종 단일 투영 모델에 포함되지 않는다.

반사실 비용과 손실 정의

매 optimizer 갱신에서 현재 가중치를 고정한 채 전문가 e∈{1,2,3,4}를 두 공간 블록에 동일하게 강제하는 네 개의 반사실 예측을 순차적으로 계산한다. 후보 계산 중 dropout은 끄고, 모든 후보에 현재 라우터의 동일한 detached top-1 gate를 적용한다. 후보 예측과 그로부터 계산한 비용은 gradient를 받지 않는다. 유효 목표가 한 개 이상인 노드·window j의 전문가 비용 c_(j,e)는 미래 12시점의 원속도 단위 유효 목표 MAE다.

구체적으로 노드·window j에서 목표 h의 원관측 지시자를 m_(j,h)라 하면 c_(j,e)=Σ_(h=1)^12 m_(j,h)|ŷ_(j,e,h)−y_(j,h)|/Σ_(h=1)^12 m_(j,h)다. 이는 연구 방법의 마스크 MAE를 하나의 노드·window와 강제 전문가 e에 제한한 식이다. 분모가 0이면 그 j는 네 전문가 비용의 비교와 아래 평균에서 제외한다. 따라서 관측되지 않은 미래 목표에 임의 비용을 부여하지 않는다.

```
r_(j,e) = c_(j,e) − min_a c_(j,a)
D       = mean over valid j and experts e of r_(j,e)
N       = mean over valid j of Σ_e p_(j,e) · r_(j,e)
L_cost  = N / D,                if D > τ_num
          0,                    otherwise
```

p_(j,e)는 현재 라우터의 네 전문가 확률이다. D는 비용 차이가 거의 없는 사례에서 무의미하게 커지는 정규화 값을 막기 위한 기준이다. 임의 epsilon으로 분모를 바꾸지 않고 FP32의 단위 반올림 오차 u=eps_fp32/2, $\gamma_{12}=12u/(1-12u)$, τ_num=$2\gamma_{12}$·max(1,max|c|)를 사용한다. D≤τ_num이면 수치적으로 구별할 선택 비용이 없다고 보고 정확히 0으로 둔다. 손실의 유한성과 0≤L_cost≤4 범위도 확인한다. 확률 경로의 gradient는 라우터 입력 encoder까지 전달하되 반사실 예측과 비용으로 역전파하지 않는다.

손실 범위는 비용과 확률의 정의에서 따라온다. 각 j,e에서 최소 비용을 빼므로 r_(j,e)≥0이고, softmax 확률은 p_(j,e)≥0, Σ_e p_(j,e)=1이다. 따라서 0≤Σ_e p_(j,e)r_(j,e)≤Σ_e r_(j,e)이고, 유효 j에 평균을 취하면

$0 \le N \le 4D$다. $D > \tau_num$일 때 양수 D로 나누면 $0 \le L_cost \le 4$가 된다. γ_{12}는 단위 반올림 오차 u가 있는 FP32에서 길이 12 합산의 누적 오차를 $12u/(1-12u)$로 묶는 수치 경계이고, $2\gamma_{12}$와 최대 비용 크기를 곱해 비용 차이가 반올림 잡음 규모에 머무는 경우를 분리한다. 이는 관측된 교통 변화의 임계값이 아니라 계산 정밀도에 관한 판정이다.

기존 주손실과 역사적 보조 손실은 유지하고 L_cost 계수만 학습 1 epoch의 0에서 20 epoch의 0.01까지 선형으로 올린다. 계수가 0이면 반사실 분기를 아예 실행하지 않는다. 별도 동등성 검사에서 이 경로의 모델·optimizer·난수 상태가 기존 학습 경로와 정확히 같음을 확인했다. 두 데이터셋의 실제 그래프에서 양의 계수로 짧은 GPU 갱신도 통과했다. 이는 구현의 수치·자원 경로 검증이며 예측 성능 검증은 다음의 새 run에서만 이뤄졌다.

비교와 결과

기존 네 전문가 체크포인트 여섯 개의 검증된 날짜별 시험 집계를 고정 control로 재사용했다. 두 데이터셋 × 세 seed의 보조 손실 treatment 여섯 개를 새로 학습하고, 같은 데이터셋·seed·현지 날짜를 짝지은 10,000회 복원추출을 수행했다. 각 재표집의 전체 MAE는 날짜별 MAE의 단순평균이 아니라 선택 날짜의 절대오차 합/유효 원소 수로 다시 계산한다. 일차 우월성 조건은 MAE_cost−MAE_control의 단측 95% 분위수가 0 미만인 것이다. 마지막 시점과 이미 고정한 극단 조건 지표는 설명용 부작용 진단이고 일차 판정을 대체하지 않는다. 기존 control의 시험 집합을 다시 실행하지 않았다.

데이터셋	기존 네 전문가 전체 MAE	비용 손실 추가 전체 MAE	추가−기존, 세 seed 평균 ± 표본편차	우월성 통과
METR-LA	3.062838 ± 0.003345	3.065543 ± 0.004390	+0.002705 ± 0.007491	1/3 seed
PeMSD4	1.518178 ± 0.003681	1.519194 ± 0.004350	+0.001016 ± 0.001023	0/3 seed

표 6. 비용 민감 보조 손실 추가 전후의 전체 평균절대오차와 우월성 통과 수.

두 데이터셋의 세 seed 방향이 일치하지 않았고 평균 전체 MAE는 조금 높았다. 학습 중 비용 목적과 라우터 confidence가 변화한 것은 관측됐지만 예측 오차 감소로 이어지지 않았다. 따라서 보조 손실을 기본 손실로 승격하지 않고, 최종 모델에서는 라우터 구조 자체를 사용하지 않는다. 이 결과는 지금 시험한 반사실 정의·계수·입력과 데이터셋에 한정된다.

참고문헌

[1] Yu, B., Yin, H., and Zhu, Z. (2018). Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting. Proceedings of the 27th International Joint Conference on Artificial Intelligence, 3634-3640. https://doi.org/10.24963/ijcai.2018/505

[2] Li, Y., Yu, R., Shahabi, C., and Liu, Y. (2018). Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting. International Conference on Learning Representations.

[3] Kim, S., Park, J., and Choi, Y. (2021). Traffic Speed Prediction Based on Graph Neural Networks for Intelligent Transportation System. Journal of Korean Society of Intelligent Transport Systems, 20(1), 70-85. https://doi.org/10.12815/kits.2021.20.1.70

[4] Park, B., Bae, S. H., and Jung, B. (2021). Speed Prediction of Urban Freeway Using LSTM and CNN-LSTM Neural Network. Journal of Korean Society of Intelligent Transport Systems, 20(1), 86-99. https://doi.org/10.12815/kits.2021.20.1.86